

# 第三章 线性代数方程组的迭代解法


/\* Iterative Techniques for Solving Linear Systems \*/

如何快速求解系数为大型稀疏矩阵的方程组

$$A \vec{x} = \vec{b}$$

**思路：**与解方程  $f(x)=0$  的不动点迭代相似。

 **研究 内容：**

 如何建立迭代格式？

 向量序列的收敛条件？

 收敛速度？

 误差估计？

## 迭代法思想:

$$\vec{x} = B \vec{x} + \vec{f}$$

$$\vec{x}^{(k+1)} = B \vec{x}^{(k)} + \vec{f}$$

### ➤ 如何建立迭代格式？

分裂  $A=M-N$ ,  $(M-N)x=b$  ,

构造  $Mx^{k+1}=Nx^k + b$

若  $M$  可逆,  $x^{k+1} = M^{-1}Nx^k + M^{-1}b$

$B=M^{-1}N$  被称为迭代法的**迭代矩阵**

**目标：**

**精度可控，迭代收敛。**

# § 1 三种迭代法

/\* Jacobi , Gauss-Seidel and SOR Iterative Methods \*/

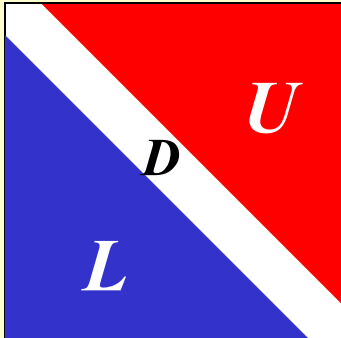
## ► Jacobi Iterative Method

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \dots \quad \dots \quad \dots \quad \dots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases}$$

$a_{ii} \neq 0$

$$\begin{cases} x_1 = \frac{1}{a_{11}}(-a_{12}x_2 - \dots - a_{1n}x_n + b_1) \\ x_2 = \frac{1}{a_{22}}(-a_{21}x_1 - \dots - a_{2n}x_n + b_2) \\ \dots \quad \dots \quad \dots \quad \dots \\ x_n = \frac{1}{a_{nn}}(-a_{n1}x_1 - \dots - a_{nn-1}x_{n-1} + b_n) \end{cases}$$

写成矩阵形式：



The diagram shows a square matrix  $A$  partitioned into three triangular regions. The main diagonal is white and labeled  $D$ . The lower-left triangle is blue and labeled  $L$ . The upper-right triangle is red and labeled  $U$ .

$$A\bar{x} = \bar{b} \Leftrightarrow (D + L + U)\bar{x} = \bar{b}$$

$$\Leftrightarrow D\bar{x} = -(L + U)\bar{x} + \bar{b}$$

$$\Leftrightarrow \bar{x} = -D^{-1}(L + U)\bar{x} + D^{-1}\bar{b}$$

$$\bar{x}^{(k+1)} = \underbrace{-D^{-1}(L + U)\bar{x}^{(k)}}_B + \underbrace{D^{-1}\bar{b}}_{\bar{f}}$$

$$A = \begin{array}{|c|} \hline \begin{array}{c} \text{red triangle} \\ U \end{array} \\ \hline \begin{array}{c} \text{blue triangle} \\ L \end{array} \\ \hline \end{array}$$

**Jacobi 迭代法：**

$$\begin{aligned} A\bar{x} &= \bar{b} \Leftrightarrow (D + L + U)\bar{x} = \bar{b} \\ &\Leftrightarrow D\bar{x} = -(L + U)\bar{x} + \bar{b} \\ &\Leftrightarrow \bar{x} = -D^{-1}(L + U)\bar{x} + D^{-1}\bar{b} \end{aligned}$$

$$\bar{x}^{(k+1)} = \underbrace{-D^{-1}(L + U)}_{\mathbf{B}} \bar{x}^{(k)} + \underbrace{D^{-1}\bar{b}}_{\mathbf{f}}$$

**Jacobi 迭代阵**

## ➤ Gauss - Seidel Iterative Method

$$x_1^{(k+1)} = \frac{1}{a_{11}} (-a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - a_{14}x_4^{(k)} - \cdots - a_{1n}x_n^{(k)} + b_1)$$

$$x_2^{(k+1)} = \frac{1}{a_{22}} (-a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)} + b_2)$$

只存一组向量即可。

$$x_3^{(k+1)} = \frac{1}{a_{33}} (-a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - a_{34}x_4^{(k)} - \cdots - a_{3n}x_n^{(k)} + b_3)$$

... ..

$$x_n^{(k+1)} = \frac{1}{a_{nn}} (-a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - a_{n3}x_3^{(k+1)} - \cdots - a_{nn-1}x_{n-1}^{(k+1)} + b_n)$$

写成矩阵形式：  $\bar{x}^{(k+1)} = -D^{-1}(L\bar{x}^{(k+1)} + U\bar{x}^{(k)}) + D^{-1}\bar{b}$

$$\Leftrightarrow (D + L)\bar{x}^{(k+1)} = -U\bar{x}^{(k)} + \bar{b}$$

$$\Leftrightarrow \bar{x}^{(k+1)} = \underbrace{-(D + L)^{-1}U}_{B}\bar{x}^{(k)} + \underbrace{(D + L)^{-1}\bar{b}}_{\bar{f}}$$

Gauss-Seidel  
迭代阵

$$A = \begin{array}{|c|} \hline \begin{array}{c} \text{Red triangle (U)} \\ \text{Blue triangle (L)} \\ \text{White diagonal (D)} \end{array} \\ \hline \end{array}$$

$$Ax = b \Leftrightarrow (D + L)x^{k+1} = -U x^k + b$$

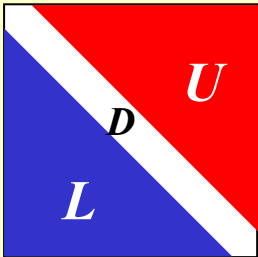
**Gauss-Seidel 迭代法：**

$$\Leftrightarrow (D + L)\bar{x}^{(k+1)} = -U\bar{x}^{(k)} + \bar{b}$$

$$\Leftrightarrow \bar{x}^{(k+1)} = \underbrace{-(D + L)^{-1}U\bar{x}^{(k)}}_{\mathbf{B}} + \underbrace{(D + L)^{-1}\bar{b}}_{\bar{f}}$$

**Gauss-Seidel  
迭代阵**

## ➤ Successive Over-relaxation (SOR) Iterative Method

$A =$  

$$\omega Ax = \omega b \stackrel{\omega \neq 0}{\iff} M = D + \omega L,$$
$$N = (1 - \omega)D - \omega U$$
$$\omega A = M - N$$
$$(D + \omega L)x^{k+1} = [(1 - \omega)D - \omega U]x^k + \omega b$$

超松弛(SOR)迭代法：

$$x^{k+1} = \underbrace{(D + \omega L)^{-1}[(1 - \omega)D - \omega U]}_B x^k + \underbrace{\omega (D + \omega L)^{-1}b}_{\vec{f}}$$

SOR  
迭代阵

问题： $\omega < 1$ 时称为低松弛， $\omega > 1$ 时称为超松弛，  
那么 $\omega = 1$ 时，SOR迭代法是什么迭代法？

## § 2 迭代法收敛性

/\* Convergence of the three Iterative Methods \*/

### ➤ 迭代序列的收敛条件



## 回顾：向量范数 /\* vector norms \*/



常用向量范数：

$$\|\bar{x}\|_1 = \sum_{i=1}^n |x_i|$$

$$\|\bar{x}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$$

$$\|\bar{x}\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}$$

$$\|\bar{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

$$\text{注：} \lim_{p \rightarrow \infty} \|\bar{x}\|_p = \|\bar{x}\|_\infty$$

**定义** 向量序列  $\{\bar{x}^{(k)}\}$  **收敛**于向量  $\bar{x}^*$  是指对每一个  $1 \leq i \leq n$  都

有  $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*$ 。可以理解为  $\|\bar{x}^{(k)} - \bar{x}^*\|_\infty \rightarrow 0$

矩阵范数 :  $\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$  ( 行和范数 )

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \quad (\text{列和范数})$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} \quad (\text{谱范数 /* spectral norm */})$$

Frobenius 范数

$$\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2} \quad \text{—— 向量} \|\cdot\|_2 \text{的直接推广}$$

**引理：** 设 $\|x\|$ 是在 $R^n$  上一个范数，则 $\|x\|$ 是 $x$ 的分量 $x_1, x_2, \dots, x_n$ 的连续函数.

**定理：**  $R^n$  上任意两种范数都等价.

**定理：** 设 $A \in R^{n \times n}$ ,

( 1 ) 对任意从属范数  $\|\cdot\|$  , 有

$$\rho(A) \leq \|A\|$$

( 2 ) 任给 $\varepsilon > 0$  , 存在一种 $A$ 的从属范数 $\|\cdot\|_\varepsilon$  , 使得

$$\|A\|_\varepsilon \leq \rho(A) + \varepsilon.$$

**定义** 矩阵序列  $A^{(k)} = (a_{ij}^{(k)}) \in R^{n \times n}$  收敛于矩阵  $A$  是指对每一个  $1 \leq i, j \leq n$  都有  $\lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij}$ 。此时称  $A$  为矩阵序列  $A^{(k)}$  的极限，记为  $A = \lim_{k \rightarrow \infty} A^{(k)}$

类似向量序列收敛性结论： $A^{(k)} \rightarrow A \Leftrightarrow \|A^{(k)} - A\| \rightarrow 0$

**定理** 设  $A \in R^{n \times n}$ ，当  $k \rightarrow \infty$  时， $A^k \rightarrow 0$  的充要条件是  $\rho(A) < 1$ 。

证明：若  $\rho(A) < 1$ ，则由上述定理可以选择一种范数，使得

$\|A\| < 1$ ，因此由矩阵的相容性得

$$\|A^k\| \leq \|A\|^k \rightarrow 0$$

于是充分性得证。

**定理** 设  $A \in R^{n \times n}$  , 当  $k \rightarrow \infty$  时,  $A^k \rightarrow 0$  的充要条件是  $\rho(A) < 1$  。

**必要性证明：**

设  $\rho(A) \geq 1$  , 令  $\lambda$  为某一使  $|\lambda| \geq 1$  的特征值 , 设  $x$  为对应特征向量 , 则

$$\|A^k\| \|x\| \geq \|A^k x\| = \|\lambda^k x\| \geq \|x\| .$$

意味着对所有的  $k$ ,  $\|A^k\| \geq 1$  , 矛盾。  
于是必要性得证。

## ➤ 迭代法的收敛性判别

对任何初始向量 $x^0$ ，上述迭代法

$$\vec{x}^{(k+1)} = B \vec{x}^{(k)} + \vec{f}$$

收敛的充要条件是  $\rho(B) < 1$ .

## Matlab主程序：谱半径判断敛散性

```
function H=testspect(B)
```

```
    H=eig(B);
```

```
    Sp=norm(H, inf); %按模取最大特征值
```

```
    if Sp>=1
```

```
        disp('迭代序列发散，谱半径Sp和特征值H如下：')
```

```
    else
```

```
        disp('迭代序列收敛，谱半径Sp和特征值H如下：')
```

```
    end
```

```
    Sp
```

**Neumann引理** 矩阵幂级数  $\sum_{k=0}^{\infty} A^k$  收敛的充要条件是  $\rho(A) < 1$ ,  
 且当  $\rho(A) < 1$  时有

$$I + A + \cdots + A^k \cdots = (I - A)^{-1}$$

证明：若  $\sum_{k=0}^{\infty} A^k$  收敛，则  $A^k \rightarrow 0$ ，从而  $\rho(A) < 1$

反之，若  $\rho(A) < 1$ ，则  $I - A$  的特征值为  $1 - \lambda_i, i = 1, 2, \cdots, n$

由于  $(I - A)(I + A + \cdots + A^k) = (I - A^{k+1})$

得  $(I + A + \cdots + A^k) = (I - A)^{-1}(I - A^{k+1})$

当  $k \rightarrow \infty$  时，有  $A^k \rightarrow 0$  故

$$I + A + \cdots + A^k + \cdots = (I - A)^{-1}$$

## Banach引理

若矩阵  $A \in R^{n \times n}$  非奇异，对任何  $E \in R^{n \times n}$  且当  $\|A^{-1}\| \cdot \|E\| < 1$  时，则有  $A + E$  非奇异，并且

$$\|(A + E)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|E\|}$$

证明：设  $B = -A^{-1}E$ ，则  $\|B\| < 1$ ，由上一定理可知  $I - B$  非奇异，且

$$I + B + \cdots + B^k \cdots = (I - B)^{-1}$$

因此

$$\|(I - B)^{-1}\| \leq \frac{1}{1 - \|B\|} \leq \frac{1}{1 - \|A^{-1}\| \cdot \|E\|}$$

但是  $A + E = A(I + A^{-1}E) = A(I - B)$

所以  $A + E$  是非奇异的，并

$$\|(A + E)^{-1}\| = \|(I - B)^{-1} A^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \cdot \|E\|}$$





**定理** 设  $A \in R^{n \times n}$ , 当  $k \rightarrow \infty$  时,  $A^k \rightarrow 0$  的充要条件是  $\rho(A) < 1$ .

**定理(Neumann引理)** 矩阵幂级数  $\sum_{k=0}^{\infty} A^k$  收敛的充要条件是  $\rho(A) < 1$  且当  $\rho(A) < 1$  时有

$$I + A + \cdots + A^k \cdots = (I - A)^{-1}$$

**定理** 若矩阵  $B$  对某个从属范数满足  $\|B\| < 1$ , 则必有

$$(1) \ I \pm B \text{ 可逆}; \quad (2) \ \left\| (I \pm B)^{-1} \right\| \leq \frac{1}{1 - \|B\|}$$

**定理** 若  $A$  对称, 则有  $\|A\|_2 = \rho(A)$

$\rho(B)$ 一般难以计算，故而考虑迭代法收敛的充分条件 $\|B\| < 1$ .